

Projekt_Moc_Testu

Jakub Ignatik

10 marca 2018

Wprowadzenie

Celem projektu jest sprawdzenie mocy testów normalności dla danych z rozkładu t-Studenta. Wykorzystam dwa testy: test Shapiro-Wilka oraz Jarque-Bera.

Hipoteza: Podejrzewam, że wraz ze wzrostem liczby stopni swobody spada moc testu, gdyż rozkład t-Studenta wystrza się, oddalając się od rozkładu normalnego. Z kolei wraz ze wzrostem liczby danych moc testu rośnie, gdyż przy większej liczbie danych łatwiej zauważyć odstępstwo od rozkładu normalnego. Jeśli zaś zwiększamy współczynnik ufności (zwiększa się obszar krytyczny), to moc również rośnie, bo jest większa szansa, że wykres z fałszywą hipotezą trafi do obszaru krytycznego.

Dane: Rozważam dane o długości od 5 do 105. Stopnie swobody ustawiłem od 1 do 10, gdyż zauważyłem potem, że przy wyższej liczbie stopni swobody moce testu oscylują na tyle blisko siebie, że zaciera się widoczna różnica między nimi. Wybrałem cztery poziomy istotności: 0.001, 0.01, 0.05 oraz 0.1. Liczbę symulacji ustawiłem na 1000.

Wizualizacja

Na początku załaduję biblioteki, wprowadzę podane we wprowadzeniu wartości oraz stworzę ramkę danych dla kombinacji stopni swobody, poziomów istotności i długości danych.

```
library(dplyr)

## Warning: package 'dplyr' was built under R version 3.4.3

library(tidyr)

## Warning: package 'tidyr' was built under R version 3.4.3

library(ggplot2)

## Warning: package 'ggplot2' was built under R version 3.4.3

library(tseries)

## Warning: package 'tseries' was built under R version 3.4.3

set.seed(111)
#ilość symulacji
N <- 1000
#stopnie swobody
dfs <- seq(1,10,by=1)
#poziomy istotności
alphas <- c(.001, .01, .05, .1)
#długości próby
sample_1 <- seq(5,105,by=10)

params <- expand.grid(dfs, alphas, sample_1)
names(params) <- c("dfs", "alpha", "length")
```

Następnie obliczam moce pierwszego testu (Shapiro-Wilka) i dodaję je do wcześniej utworzonej ramki danych.

```

powers <- sapply(1:nrow(params), function(p){
  df <- params[p, 1]
  alpha <- params[p, 2]
  l <- params[p, 3]
  p_sim <- sapply(rep(df, N), function(x){
    my_sample <- rt(1, df)
    shapiro.test(my_sample)$p.value
  })
  mean(p_sim < alpha)
})
power_df <- bind_cols(params, power = powers)


```

Dla utworzonej ramki danych tworzę wykres. Otrzymuję wykres dla testu Shapiro-Wilka.


```

power_df %>% ggplot(aes(x = length,
  y = power,
  col = factor(dfs))) +
  geom_line() +
  facet_wrap(~alpha, ncol = 2)

```



Podobnie postępuję, żeby otrzymać wykres dla testu Jarque-Bera. Jediną zmianą jest wprowadzenie w pętli funkcji `jarque.bera.test` zamiast `shapiro.test`.



Interpretacja

W przypadku obu testów potwierdza się postawiona na początku hipoteza.

Największą moc mają najmniejsze stopnie swobody. Na początku każdy stopień swobody znacznie obniża moc testu, ale przy większych ich ilościach różnice są nieznaczne. Również liczba danych ma znaczenie - widać wzrost liniowy na wyższych stopniach swobody, natomiast na tych niższych stopniach swobody wzrost przypomina potęgowy, a nawet logarytmiczny.

Sprawdziła się też hipoteza dotycząca współczynnika ufności. Im on jest większy, tym szybciej osiągnana jest moc testu bliska 1. Przykładowo, w teście Shapiro-Wilka przy współczynniku ufności równym 0.001 moc testu bliska jeden występuje przy ok. 60 danych, natomiast przy współczynniku ufności równym 0.1, ta liczba wynosi już tylko jakieś 40 danych.

Na uproszczenie analizy mogły mieć wpływ nieduży zakres próby oraz nieduża liczba stopni swobody. Liczb symulacji równa 1000 raczej nie spowodowała dużych uproszczeń, co sprawdziłem, podnosząc tę liczbę do 5000.